


România
Ministerul Apărării Naționale
Academia Tehnică Militară "Ferdinand I"

Facultatea de Sisteme Informatici și Securitate Cibernetică
CALCULATOARE ȘI SISTEME INFORMATICE PENTRU APĂRARE ȘI
SECURITATE NAȚIONALĂ



Platformă de Analiză Automată a Atacurilor Data Poisoning asupra unei
Infrastructuri de Învățare Federate

Coordonator Științific

Cpt. conf. dr. ing. Iulian Aciobăniței

Absolvent

Sd. Sg. Maj. Lepădatu Tudor

Conține _____ file
Inventariat sub numărul _____
Cu poziția din indicator _____
Cu termen de păstrare _____

București
An 2026

Mulțumiri pentru persoanele care au sprijinit procesul de realizare a acestei lucrări

Referatul Coordonatorului Științific

Referatul reprezintă un text în care coordonatorul științific sumarizează, ulterior finalizării conținutului efectiv, efortul pe care l-ați depus și trage concluzii cu privire la gradul de realizare a obiectivelor propuse inițial (cele prezentate în cadrul detalierii). De regulă, acest referat nu depășește cele 4 pagini alocate în acest document.

NECLASIFICAT

NECLASIFICAT

Tema Proiectului de Diplomă

Tema proiectului de diplomă (sau detalierea) reprezintă un text realizat de coordonatorul științific, în luniile următoare propunerii titlului proiectului de diplomă către facultate, în care detaliază nevoia reală a implementării unui astfel de proiect și modul în care se dorește a fi implementat. În plus, poate prezenta structura pe capitole a viitoarei lucrări, anexele ce vor fi incluse și sursele bibliografice din care studentul se va informa. De regulă, acestă detaliere nu depășește cele 4 pagini alocate în acest document.

Abstract

The Artificial Intelligence integration with tools and applications has evolved since 2020s and the cyber-security scene tries to adapt frequently. Information security and data integrity is more important than never before, being used by Machine Learning models or Neural Networks trained to perform specific tasks.

From a data science point of view, the quality of information is much important than securing it. The AI evolution has led to the creation of different attack boundaries, from changing the model parameters to perform data poisoning schemes. Confidentiality is the key in maintaining unique aspects for each entity involved in the federated learning process.

In this paper, data poisoning attacks are studied with different options in a segregated simulated infrastructure called federated learning, in which each client may change its scope intentionally or unintentionally. Each simulation has its own configuration providing data scientist with a dedicated environment for testing its machine learning algorithm againts data poisoning attacks.

Cuprins

| | |
|--|-----------|
| 1 Introducere | 1 |
| 1.1 Context | 1 |
| 1.2 Motivatia lucrarii | 2 |
| 1.3 Obiectivele lucrarii | 2 |
| 1.4 Structura lucrarii | 2 |
| 2 Notiuni Teoretice | 3 |
| 2.1 Notiuni introductive | 3 |
| 2.1.1 Diferenta dintre Machine Learning si Deep Learning | 3 |
| 2.1.2 Retea Neuronala | 3 |
| 2.2 Invatare automata federata | 3 |
| 2.2.1 Concept | 4 |
| 2.2.2 Arhitectura FL | 4 |
| 2.2.3 Procesul de antrenare FL | 6 |
| 2.2.4 Exemple in viata reala | 7 |
| 2.3 Atacuri de tip Data Poisoning | 8 |
| 2.3.1 Definirea tipurilor de atac | 8 |
| 2.3.2 Vectori de atac | 8 |
| 2.3.3 Atacul Data poisoning | 9 |
| 2.3.4 Impactul poisoning in Federated Learning | 9 |
| 2.4 Alte Notiuni | 10 |
| 2.4.1 Docker | 10 |
| 2.4.2 Python | 10 |
| 2.4.3 Rest API | 10 |
| 3 Proiectare, Implementare si Testare | 11 |
| 3.1 Cerintele Software | 11 |
| 3.1.1 Cerintele functionale | 11 |
| 3.1.2 Cerintele nefunctionale | 11 |
| 3.2 Arhitectura platformei | 11 |
| 3.2.1 Containere | 11 |
| 3.2.2 Server | 11 |
| 3.3 Testare | 11 |
| 4 Rezultate si Metrici Simulari | 12 |
| 4.1 Evaluare Performante | 12 |
| 4.1.1 Scalabilitatea Simularilor | 12 |
| 4.1.2 Scalabilitatea platformei | 12 |
| 4.2 Evaluare Rezultate | 12 |
| 4.2.1 Performante Gaussian Noise | 12 |
| 4.2.2 Performante Label-Flip | 12 |
| 4.2.3 Performante Backdoor | 12 |
| 5 Concluzii si dezvoltare ulterioara | 13 |
| 5.1 Starea Curenta | 13 |
| 5.2 Dezvoltare Ulterioara | 13 |
| 5.3 Tabele | 13 |
| 5.4 Imagini | 15 |
| 5.5 Liste | 15 |
| 5.6 Formule Matematice | 15 |
| 5.7 Note de Subsol. Citări | 16 |
| 5.8 Etichete. Referințe | 16 |
| Bibliografie | 17 |

Listă de figuri

| | |
|---|----|
| 2.1 Imaginea 2.2.2: Modele Federated Learning | 4 |
| 2.2 Imagine 2.2.3.1: Arhitectura internă a unui dispozitiv | 6 |
| 2.3 Imagine 2.2.3.2: Procedee în invatare automată federată | 7 |
| 5.1 Arhitectura unui calculator | 15 |

Listă de Abrevieri

UE Uniunea Europeană

EU *European Union*

Capitolul 1:

Introducere

1.1 Context

Odata cu dezvoltarea sistemelor de calcul moderne si a componentelor Hardware, s-au putut realiza produse software complexe cu capacitatii de stocare net superioare. Revolutia tehnologica a permis nu doar realizarea unor sarcini simple, precum calcule matematice, sau automatizarea unor dispozitive (de exemplu aprinderea automata a unui bec printr-un microcontroler), ci si posibilitatea gestionarii mai eficiente a informatiilor digitale (de la date bancare la fisiere media).

Aceasta a devenit treptat principala sursa legitima de inregistrare a oricarui tip de date (text, imagini, video, audio). Pentru a accesa si actualiza informatia digitala, s-au dezvoltat diferite versiuni de baze de date centralizate si distribuite.

Bazele de date centralizate sunt aplicatii software specializate ce folosesc resursele sistemului (a statiei) pentru a raspunde cat mai rapid interogarilor. Statiile trebuie sa detina multa putere de stocare si de procesare in comparatie cu un sistem de calcul normal destinat utilizatorilor casnici. In alta ordine de idei, s-au dezvoltat si baze de date distribuite, menite sa reduca din capacitatatile tehnice ale serverului si sa stocheze informatia sub forma descentralizata. Cautarea resursei in acest context ar presupune interogarea recursiva a fiecarei entitati pana la gasirea sa. Prin acest mod, nu doar ca statiile pot avea si capacitatati tehnice mai reduse, dar si pot pastra copii de rezerva (backup) locale pentru fiecare segment de informatie in parte.

Aceasta evolutie naturala spre descentralizare a deschis drumul unor concepte moderne precum invatatura automata federata (federated learning), unde datele nu mai sunt transferate catre un server central. În schimb, modelele sunt antrenate local, iar parametrii sunt ulterior agregati global. Astfel, se menține confidențialitatea datelor, fără a compromite performanța modelului.

Evolutia tehnologica continua a dat nastere la o serie de atacuri cibernetice menite sa destabilizeze securitatea aplicatiilor si totodata sustragerea a cat mai multe date sau identitati private in contradictie cu normele legale. Cele mai populare atacuri raportate la scara globala pentru anul curent 2025 sunt ransomware (conform ¹, in SUA s-au raportat cresteri de 149%), furtul de identitate prin exfiltrarea de credentiale, si phishing. Dezvoltarea modelelor de inteligență artificială a amplificat aceste riscuri, oferind atacatorilor instrumente automatizate pentru generarea si adaptarea atacurilor.

Pentru a limita utilizarea abuzivă a tehnologiilor bazate pe AI, Uniunea Europeană a adoptat în 2024 un set de reglementări stricte privind integrarea acestor module în aplicațiile software, prin AI Act ².

Progresul din domeniul machine learning si a Large Language Models a fost posibil ca urmare a unui volum masiv de date disponibile si a nevoii tot mai mari de analiza. Acest lucru a determinat aparitia unei noi categorii de specialisti, data scientists, dedicati colectarii si prelucrarii minutioase a datelor pentru antrenarea modelelor.

Totusi, pe măsură ce investițiile în tehnologia AI au crescut, au apărut și actori rău intenționați care încearcă să exploateze vulnerabilitățile din procesul de antrenare. Întrucât modelele moderne depind de calitatea datelor folosite, acestea au devenit o ţintă principală a atacurilor. Atacatorii se regasesc si ei intr-o pozitie constanta de adaptare la noile formalitati de securitate si incearca sa contracareze fiecare element nou. Astfel, avand in vedere complexitatea dezvoltarii unui modul de inteligenta artificiala specializat pe diferite domenii, tinta s-a redirectionat spre volumul de date pe care acestea le folosesc si care pot determina starea finala a aplicatiei.

În contextul învățării automate distribuite, literatura de specialitate identifică trei categorii majore de atacuri:

- Atacuri asupra datelor, precum data poisoning, unde setul de antrenare este manipulat pentru a altera comportamentul modelului;
- Atacuri asupra modelului, prin modificarea parametrilor sau a gradientului (de exemplu, model poisoning);
- Atacuri asupra canalului de comunicare, care vizează interceptarea sau modificarea mesajelor dintre entitățile participante.

Lucrarea de față se concentrează pe prima categorie, data poisoning, în cadrul unei infrastructuri de

invatare federate.

1.2 Motivatia lucrarii

Avand in vedere aspectele legate de posibilitatea unei interventii asupra setului de date de antrenare, atac denumit otravire a datelor (data poisoning), munca cercetatorilor s-a ingreunat. Preocuparea nu mai este primordiala asupra analizei setului de date de antrenare, cat despre mentinerea integritatii si a confidentialitatii lor. Pentru a raspunde acestor nevoi, colaborarea dintre cercetatori s-a orientat catre modele distribuite de lucru, iar invatarea federata (federated learning) a devenit una dintre principalele directii. Aceasta permite colaborarea intre participantii fara a partaja direct seturile lor de date, mentinand o bariera naturala impotriva accesului neautorizat. Totusi, desi infrastructura este diferita fata de abordarile centralizate, vulnerabilitatile ramane, iar atacurile asupra datelor utilizate local pot afecta modelul global.

In urma unei analize proprii, am putut observa diferite solutii/frameworks de simulare a procesului de invatare automata federata, dar fara o integrare cu mecanisme moderne de testare pentru atacuri precum otravirea datelor (data poisoning) amintite anterior³. Unele dintre aceste framework-uri sunt poate dificil de gestionat si configurat⁴, si nu permit extinderea usoara prin integrare altor componente. In acelasi timp, gandindu-ne la multitudinea de atacuri malware si la platformele de detectie a lor, devine clar ca in domeniul inteligentei artificiale lipseste o platforma centralizata, flexibila, dedicata testarii si evaluarii cu diferite tipuri de atacuri asupra modelelor distribuite.

Aceste limitari justifica realizarea prezentei lucrari, care isi propune dezvoltarea unei platforme de simulare capabile sa testeze atacuri de tip data poisoning intr-o infrastructura de invatatorie federata.

1.3 Obiectivele lucrarii

Plecand de la neajunsurile prezentate, ne propunem in aceasta lucrare sa venim in sprijinul comunitatii de cercetare stiintifica in domeniul securizarii solutiilor cu AI cu o platforma de simulare cu sursa deschisa ("open source"), a acestei clase de atacuri pe mai multe directii. Astfel, oferim cercetatorilor posibilitatea analizei algoritmului de antrenare propriu dezvoltat, plecand de la o retea neuronala de baza si un set de date uzuale (imagini), si testarea sa prin antrenare in diferite conditii. Platforma in sine respecta toate normele unei aplicatii software de productie, in care fiecare actiune are propria sa logica de implementare. Serviciile sunt segregate suficient de mult incat sa permita o dezvoltare ulterioara prin integrarea lor cu alte sisteme.

Rezultatele pot fi utile in contextul securizarii procesului de antrenare al algoritmului, dar si pentru analiza factorilor de risc la care e expus in acest mediu.

Cercetatorul este cel care furnizeaza algoritmul python de antrenare a proprietiei retele neuronale sau algoritmul de Machine Learning. El seteaza parametrii simularii atat pentru procesul de antrenare, cat si pentru tipul de atac de otravire a datelor. Platforma isi propune sa simuleze acest tip de atac cu ajutorul acestor setari de inceput intr-un mediu de invatare federata, furnizand la final o comparatie intre modelul antrenat folosind datele normale de antrenare si cel antrenat cu datele otravite. Aceste rezultate pot fi utile in semnalarea unui posibil risc la nivelul modelului dezvoltat, oferind mai apoi solutii de imbunatatire a implementarii sale.

1.4 Structura lucrarii

¹<https://www.dnsc.ro/vezi/document/buletin-de-indicatori-statistici-si-tendinte-de-securitate-cibernetica-h1-2025>

²<https://artificialintelligenceact.eu/wp-content/uploads/2024/11/Future-of-Life-InstituteAI-Act-overview-30-May-2024.pdf>

³<https://ibmfl-api-docs.res.ibm.com/index.html>

⁴<https://github.com/IBM/federated-learning-lib/tree/main>

Capitolul 2:

Notiuni Teoretice

In acest capitol, vor fi prezentate notiunile teoretice specifice intelegerii procesului de dezvoltare a platformei de simulare. Vom incepe cu Notiunile introductive despre concepte de Machine Learning in antiteza cu Deep Learning. In continuare, vom discuta despre invatarea federata si arhitectura unei infrastructuri federate de invatare automata, tipurile de atacuri data poisoning implementate in procesul de simulare a atacurilor, precum si alte notiuni specifice implementarii.

2.1 Notiuni introductive

Machine Learning si Deep Learning sunt doua ramuri importante ale Inteligentei Artificiale care au rolul dezvoltarii unor modele specifice rezolvării unor anumite actiuni. Pornind de la antrenarea de retele neuronale, ne orientam atentia spre setul de date de antrenare si spre actorii ce pot interveni in acest proces. Mediul in care testam ofera o perspectiva reala asupra impactului pe care il pot avea aceste atacuri la nivelul unei organizatii sau aplicatiilor.

2.1.1 Diferenta dintre Machine Learning si Deep Learning

Inteligenta Artificială (AI) este domeniul vast care înglobează orice tehnică ce permite calculatoarelor să imite comportamentul uman. Informatia a evoluat treptat odata cu imbunatatirea capabilitatilor de stocare ale dispozitivelor si aparitia programelor software complexe. De la simplul format de text, inregistrari audio, pana la imagini si video in rezolutii 4K, modul de lucru s-a diversificat constant.

La fel au evoluat si cerintele utilizatorilor, care tind sa acceada catre solutii automate care sa le rezolve problemele uzuale, precum identificarea de patterns in imagini sau chiar din video, sau generarea de text.

IA vine sa rezolve aceste probleme si sa introduca algoritmi de rezolvare specifici pentru fiecare tip de informatie furnizata.

Machine Learning este o componenta importanta din domeniul IA care se diferențiază de alte metode de antrenare prin optimizarile pe care le aduce erorilor ce apar din predictia rezultatului corect. Modelele de ML clasice se bazeaza pe interventia umana in factorul de decizie (supervised learning), mai precis datele de intrare sunt etichetate pentru a oferi un context de predictie stabil.

Deep Learning este o subcategorie a Machine Learning, care are rolul de a minimiza interventia umana si a automatiza procesul de decizie. Prin aceasta metoda se automatizeaza mare parte din extragerea caracteristicilor pe setul de date, eliminand nevoia de a defini etichete pentru fiecare valoare de intrare (unsupervised learning).

Diferenta dintre aceste doua concepte este in modul in care acesti algoritmi invata si procentul de utilizare a datelor [1]. Scopul principal al invatarii automate este predictia. Pe baza unui set de date de antrenare si de testare, se determina o anumita categorie de iesire predefinita.

2.1.2 Retea Neuronala

Retelele Neuronale sunt un subset al Machine Learning si se identifica drept infrastructura de baza din cadrul algoritmilor de Deep Learning. Denumirea de "neuronal" se refera la structura lor interna, in care fiecare caracteristica (feature) este un neuron ce interactioneaza unii cu altii. Ele sunt compuse din 3 straturi/layers: primul strat il reprezinta stratul nodurilor de intrare, al doilea strat este denumit "stratul ascuns" (hidden layer) pt ca incapsuleaza mai multe straturi, iar ultimul strat este cel de iesire in care se face predictia propriu-zisa. Straturile ascunse sunt concepute pentru a procesa iterativ datele pornind de la starea lor din nodurile de intrare pana la stratul de iesire.

2.2 Invatare automata federata

Evolutia hardware in tehnologie a condus la cresterea numarului dispozitivelor mobile (telefoane, tablete), denumite gadgets din faptul ca sunt mici, portabile si moderne. Ele au fost mai departe adoptate la scara larga, devenind obiecte indispensabile in era tehnologica ce avea sa vina.

2.2.1 Concept

Invatarea automata federata permite lucrul cu modele de ML sau chiar retele neuronale, antrenate distribuit, pe un numar mare de dispozitive in scopul rezolvării unei probleme de IA. Distribuirea sarcinilor a fost adoptata si in contextul opozitiei lucrului centralizat, pe servere ce detin capabilitati Hardware performante (placi grafice de ultima generatie), dar care genereaza costuri mari si care pot fi predispuse la amenintari de securitate cibernetica, fiind considerate SPOF(Single Point of Failure).

2.2.2 Arhitectura FL

In literatura, exista mai multe categorii de arhitecturi de invatare automata federata. In aceasta sectiune ne vom concentra pe clasificarea generala a arhitecturii unei aplicatii folosind federated learning, si vom enumera pentru o anumita categorie cum se clasifica dispozitivele utilizate.

Federated Learning, asa cum a mai fost mentionat, este organizat dintr-un server (aggregator) si multiple dispozitive client. Modul in care aceste entitati comunica este fundamentalul principal in modului de imbunatatire al invatarii.

In modul clasic al federated learning, dispozitivele client transmit actualizari ale modelului de baza la un server central care aplica asupra lor o functie de agregare, reconstruind intreg modelul de baza. Aceasta setare/model, presupune de fapt o delegare a sarcinii de invatare, insa pastreaza entitatea centrala necesara imbunatatirii solutiei. Acest fapt, nu tine sa evite posibilitatea amenintarilor cibernetice (Single Point of Failure), ci doar sa usureze costurile centralizatorului in a procesa local problema, distribuind sarcinile.

Modelul Fully decentralized (peer-to-peer) learning, ofera o noua abordare si rezolva problema cibernetica amintita. In aceasta setare nu exista aggregator, imbunatatirile fiind comunicate intre clienti interconectati. Ideea principala se bazeaza pe inlocuirea comunicarii cu aggregatorul cu cea intre dispozitive individuale printr-un protocol prestabil. In functie de numarul de dispozitive, se concepe un graf de conexiuni in care fiecare nod reprezinta un client, iar fiecare muchie un canal de comunicatie. Restricția principala este ca un dispozitiv sa fie conectat la un numar maxim limitat de dispozitive adiacente, prestabilit, in contradictie cu un graf complet (stea) specific arhitecturii clasice client-server. Nodurile isi imbunatasesc propriile variante ale retelei, si isi comunica rezultatele pe care le agrega local, realizand o medie a ponderilor. In comparatie cu modelul federated learning clasic, modelul fully decentralized nu specifica de la inceput dispozitivelor un model de baza global de la care sa porneasca in procesul de rezolvare a problemei.

| | Federated learning | Fully decentralized (peer-to-peer) learning |
|-------------------------|--|--|
| Orchestration | A central orchestration server or service organizes the training, but never sees raw data. | No centralized orchestration. |
| Wide-area communication | Typically a hub-and-spoke topology, with the hub representing a coordinating service provider (typically without data) and the spokes connecting to clients. | Peer-to-peer topology, with a possibly dynamic connectivity graph. |

Figura 2.1: Imaginea 2.2.2: Modele Federated Learning

Imaginea de mai sus ofera o privire de ansamblu asupra celor doua modele de arhitecturi si caracteristicile acestora.

| Model | Avantaje | Dezavantaje |
|---|--|---|
| Federated learning (centralized coordination) | <ul style="list-style-type: none"> mai simplu de configurat (topologie hub-and-spoke) porneste de la un model global de baza agregarea centralizata reduce sarcina de calcul pe clienti necesita mai putine conexiuni (doar client → server) gestiunea și monitorizarea sunt mai simple | <ul style="list-style-type: none"> SPOF (Single Point of Failure) – serverul central serverul poate deveni întotdeauna atacuri nu elimină riscurile cibernetice, doar distribuie munca dependenta de coordonator pentru progresul antrenării necesitatea infrastructurii centralizate permanente disponibile |
| Fully decentralized / peer-to-peer learning | <ul style="list-style-type: none"> previne atacurile specifice unui server central (evită SPOF) reziliență crescută – compromiterea unui nod nu destabilizează întregul sistem îmbunătățirile se propagă prin graf, fără entitate centrală agregare locală (fiecare nod mediază ponderile) poate scala natural dacă graful este bine proiectat | <ul style="list-style-type: none"> necesitatea conexiunii suplimentare între clienți topologie complexă, dificil de administrat nu există model global inițial furnizat tuturor performanța depinde de calitatea grafului de conexiuni nodurile multiajuns pot influența direct vecinii necesitatea protocolelor suplimentare pentru consistența actualizărilor |

Tabel 2.1: Compararea modelelor Federated Learning și Fully Decentralized Learning

In tabelul de mai sus, sunt evidențiate avantajele și dezavantajele utilizării celor două tipuri de modele federated learning.

In continuarea acestei lucrări, se va discuta preponderent despre modelul clasic federated learning, fiind unul adoptat la scară largă și care oferă performanțe bune raportate la costurile de producție.

Modelul clasic la rândul său, se cataloghează în literatură în funcție de tipul dispozitivelor care iau parte la procesul de antrenare. Sub acest filtre, există Cross-Device Federated Learning și Cross-Silo Federated Learning.

Cross-Device Federated Learning sunt dispozitivele client IoT uzuale, individuale, care comunică orchestratorului printr-un protocol prestabil.

Cross-Silo Federated Learning sunt dispozitive din instituții guvernamentale, companii, sau centre de date distribuite geografic. Instituțiile nu doresc să schimbe informații între ele sau cu un furnizor de servicii central, păstrându-si confidențialitatea, folosind federated learning pt a antrena propriul model pe datele private ale fiecaruia.

2.2.3 Procesul de antrenare FL

Primul pas este stabilirea conexiunii dintre dispozitive și un server de agregare ce permite antrenare distribuită a tipului de rețea neuronala sau model ML specific problemei. Odată stabilit canalul, în fază de configurație initială, serverul trimite dispozitivelor starea de bază a rețelei neuronale, ponderile, în vederea antrenării individuale. Fiecare rețea se antrenează cu datele extrase local (on device) și își îmbunătățește configurația internă la fiecare epocă pentru o perioadă de timp bine determinată.

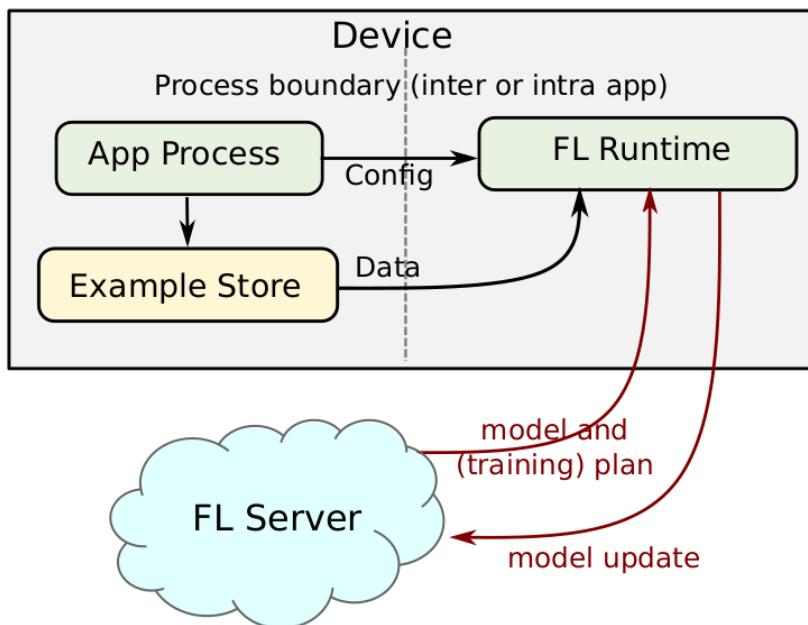


Figura 2.2: Imagine 2.2.3.1: Arhitectura internă a unui dispozitiv

Figura de mai sus descrie operațiile specifice programului Software care se ocupa de antrenarea rețelei/modelului. Putem observa cum dispozitivele primesc un plan de antrenare de bază pe care îl vor antrena local pe un set de date limitat.

Desi acest pas nu aduce un procent de îmbunătățiri foarte mari, în faza următoare, dispozitivele vor transmite configurațiile curente ale rețelelor lor la orchestrator (server). Rutina FL_Runtime extrage configurația nouă locală și îi comunica serverului pentru o posibilă actualizare a sa.

In cele din urmă, entitatea centrală combina toate aceste ponderi aplicand o funcție de agregare și în cazul îmbunătățirii setului de ponderi, modifica configurația de bază și o retransmite dispozitivelor pereche. Dacă ponderile noile nu se îmbunătățesc semnificativ față de configurația de bază, atunci se patrează aceasta din urmă, iar în caz contrar se actualizează cu noile ponderi.

In figura de mai sus, se poate observa într-o manieră continuă, fluxul de comunicare dintre dispozitive și serverul agregator, precum și operațiile specifice fiecărei entități dintr-o runda de mesaje.

Securitatea protocolelor de agregare, utilizate în comunicării dintre clienti și orchestrator, este o componentă importantă în procesul federated learning. De menționat este faptul că, în această topologie,




Figura 2.3: Imagine 2.2.3.2: Procedee in invatare automata federata

comunicatiile au loc criptat, folosind metode specifice precum criptare homomorfica, sau chiar OTP, insa securitatea datelor de pe dispozitive ramane la latitudinea acestuia.

2.2.4 Exemple in viata reala

Federated Learning s-a extins rapid în numeroase domenii datorită capacitatii sale de a antrena modele performante fără a colecta sau centraliza date sensibile. Prin păstrarea informațiilor la nivelul fiecărui dispozitiv sau instituției, FL reduce riscurile asociate scurgerilor de date și permite colaborarea între entități care altfel nu ar putea împărtăși date brute. În continuare sunt prezentate câteva exemple reprezentative ale utilizării sale în aplicații din lumea reală.

Industria și IoT

- Mentenanță predictivă:** Vehiculele moderne, utilajele industriale și echipamentele IoT generează constant date despre starea componentelor. FL permite antrenarea unui model comun care poate prezice momentul oportun pentru realizarea mentenanței fără a colecta date brute de la fiecare dispozitiv.
- Dispozitive de monitorizare:** Senzori portabili și dispozitive smart home pot furniza statistici privind activitatea sau consumul energetic, păstrând datele utilizatorilor la sursă.

Medical

- Diagnostic, prognoză și imagistică:** FL este folosit în spitale și clinici pentru detectarea celulelor cancerioase din imagini RMN, CT sau radiografii, fără transferul imaginilor către un server central.
- Confidențialitate menținută la sursă:** Fiecare instituție medicală antrenează local o parte din model, partajând doar actualizările, ceea ce permite colaborarea fără a încălca regulile privind datele pacienților.

Financiar

- Detectarea fraudelor:** Instituțiile financiare pot îmbunătăți detectarea tranzacțiilor suspecte analizând tipare comune fără a expune date sensibile despre clienți.

Servicii și experiență utilizator

- Recomandări personalizate:** Platformele de streaming și aplicațiile mobile generează recomandări local, pe dispozitiv, fără a trimite istoricul complet al utilizatorului către server.
- Analiză comportamentală:** FL poate analiza activitatea utilizatorilor pentru a sugera rutine sănătoase sau îmbunătățiri ale stilului de viață, păstrând confidențialitatea datelor.

Securitate și privacy

- **Supraveghere fără expunerea datelor sensibile:** Modelele de recunoaștere facială pot fi antrenate fără a transmite imagini reale, doar parametrii aferenți.
- **Analiză a sentimentelor:** FL poate analiza reacțiile utilizatorilor la evenimente sociale (like-uri, share-uri, comentarii) fără colectarea directă a acestor date de către platformă.

2.3 Atacuri de tip Data Poisoning

In acest capitol se va discuta una dintre avantajele pe care le ofera mediul federated learning atacatorilor si ce inseamna acest lucru pentru fluxul configuratiei modelului. Vom incepe cu definirea vectorilor de atac si concentrarea pe una dintre categorii, data poisoning. In continuarea lucrarii, vom analiza impactul pe care il are acest tip de atac asupra infrastructurii federate de invatare si riscurile pe care le introduce, precum si cateva propuneri de identificare si constientizare a existentei sale.

2.3.1 Definirea tipurilor de atac

In literatura de specialitate, atacurile asupra unui model de ML sau asupra unei retele neuronale sunt definite drept atacuri adversariale (adversarial attacks). Aceasta clasa de atacuri are rolul de a produce modificari in comportamentul normal al modelului intr-un mod indizerabil. Conform lucrarii [1], in functie de nivelul de scop al unui atac, putem avea:

- **Atacuri fără țintă (untargeted attacks)** Scopul este reducerea acurateții generale a modelului sau chiar destabilizarea completă a acestuia. Un exemplu pentru clasificarea imaginilor este introducerea unui zgomot care degradează calitatea setului de date. O altă metodă este modificarea etichetelor din setul de antrenare, de exemplu atribuirea etichetei *leu* unor imagini care în mod normal ar trebui etichetate drept *pisică*.
- **Atacuri țintite (targeted attacks)** Denumite și *backdoor attacks*, deoarece urmăresc modificarea comportamentului modelului doar pentru un anumit subset de date, fără a afecta vizibil acuratețea globală. Continuând exemplul anterior, pentru un anumit tip de imagini ce reprezintă pisici într-o anumită poziție, se poate introduce un artefact vizual menit să păcălească modelul și să clasifice pisica drept *leu*. Astfel apare un backdoor activ doar pentru acele imagini precise.

Plecand de la aceasta categorisire, există o multime de modalitati prin care un atacator poate submina capacitatea de predictie a modelului. Mediul federated learning introduce prin constructie o serie de intrebări la care trebuie gasit un raspuns pentru a determina prin ce moduri un adversar se poate infiltră si poate profita de anumite drepturi pentru a introduce incertitudine in antrenarea sau reglarea (fine-tuning) a modelelor.

2.3.2 Vectori de atac

Analiza amenintarilor asupra modelelor de ML, a introdus o serie de posibile vulnerabilitati asupra componentelor ce alcătuiesc fluxul de invatare. Un atacator isi poate alege zona de interes, pe baza posibilitatilor de exploatare a sistemului respectiv.

Vectorii de atac cunoscuți sunt:

- **Data Poisoning** Cand adversarul încearcă să corupă setul de date de antrenare cu scopul defectării modelului încă de la început.
- **Model Update Poisoning** Cand adversarul se folosește de o vulnerabilitate ce îi permite modificarea configuratiei parametrilor trimisi către orchestrator.
- **Evasion attack** Cand adversarul are acces la datele de testare și le poate modifica în momentul inferenței.

In functie de gradul de acces la sistemele gazda, modelul poate fi inspectat in diferite moduri:

- **Black Box** Adversarul nu are abilitatea sa inspecteze parametrii modelului inainte sau in timpul atacului.

- **Stale Box** Adversarul poate inspecta doar o versiune incipienta a modelului. Aceasta capabilitate apare si in federated learning cand adversarul are acces la runde de antrenare ale clientului.
- **White Box** Adversarul are abilitatea de a inspecta direct parametrii modelului. Acest scenariu se bazeaza pe un grad de acces superior al adversarului asupra sistemului.

Pe baza acestor scenarii, atacatorul poate aplica o serie de tehnici pentru modificarea starii modelului. In contextul lucrarii de fata, se va discuta scenariul stale box, adversarul avand posibilitatea doar de a introduce un atac Data Poisoning in runde de antrenare, datele corupte fiind introduse o singura data in procesul de reglare a modelului (fine-tuning).

2.3.3 Atacul Data poisoning

Acest tip de atac presupune coruperea datelor de antrenare sau de testare, prin diferite tehnici specifice, la nivelul dispozitivului clientului. In aceasta paradigma, atacul poate fi considerat la fel de bine targeted sau untargeted intrucat depinde de intenția adversarului si de potentialul risc in divulgarea punctului de exploatare de care dispune.

În practica atacurilor de tip Data Poisoning, adversarul poate manipula atât conținutul datelor, cât și etichetele acestora, efectele fiind de obicei greu de observat la nivel local. În mediul federated learning această dificultate este amplificată, deoarece orchestratorul nu are acces direct la datele brute ale clientilor. Astfel, orice modificare realizată pe un dispozitiv compromis intră automat în procesul de antrenare, fiind tratată ca o contribuție legitimă. În mod particular, chiar și un număr redus de exemple otrăvite poate introduce un comportament persistent în modelul global, mai ales dacă atacul este repetat pe durata mai multor runde.

In contextul solutiei propuse, se va discuta despre impactul atacului asupra unui set de imagini si tipurile de metode pentru a le altera, asa cum se poate vedea in tabelul 2.3.3.

| Tip atac | Descriere |
|--------------------|---|
| Gaussian noise | Introducerea unui zgomot aleator în imagini sau în vectorii de caracteristici, cu scopul degradării calității datelor și scăderii performanței modelului. |
| Label flip | Modificarea intenționată a etichetelor din setul de antrenare, astfel încât exemple corecte sunt asociate cu clase greșite, afectând procesul de învățare. |
| Backdoor injection | Inserarea unui artefact vizual sau a unui tipar specific într-un subset mic de date, astfel încât modelul să învețe un comportament anormal activat doar de acel trigger. |

Tabel 2.2: Tipuri de atacuri Data Poisoning

Prin aceste tipuri de atacuri adversariale, impactul asupra modelului are loc pe o perioada determinata de timp, de obicei mai lunga, si produce variatii in predictia finala.

2.3.4 Impactul poisoning in Federated Learning

Mediu de invatare federata a introdus o serie de amenintari cibernetice preponderent la nivelul dispozitivelor clientilor, acestea fiind cele mai vulnerabile din punctul de vedere al aplicarii unui atac de otravire a datelor. Clientii sunt producatorii unui model calitativ care sa ofere predictii legitime in diferite scenarii.

Cand se discuta despre alterarea etichetelor (Label Flip Attack) atunci la o prima vedere, utilizatorul nu si-ar da seama decat in urma unei inspectii amanuntite. Pentru acest tip de atac, exista tehnici de verificare si filtrare ce pot determina daca un tip de informatie este catalogata corect inainte de antrenare.

Efectele unui data poisoning pot persista chiar și după eliminarea datelor corupte, deoarece modelul învăță un tipar greșit care nu dispără imediat fără o reantrenare completă. Acest lucru este relevant mai ales pentru atacurile backdoor, care rămân inactive până la apariția unui trigger vizual, fără a afecta acuratețea generală. Din acest considerent, atacurile tintite (targeted attacks) sunt deosebit de periculoase in contextul unui mediu de invatare federata pentru ca datele corupte se ascund in interiorul configuratiilor particulare ale clientilor. Aceste configuratii sunt transmise mai departe la agregator care aplicand functia sa de agregare, amplifica negativ starea modelului.

Având în vedere aceste particularități, devine esențială analizarea metodelor de apărare și a mecanismelor prin care pot fi detectate contribuțiiile malicioase. Provocarile in acest domeniu conduc la o serie tot mai mare de utilitare sau platforme ce permit detectarea facilă a acestor atacuri si imbunatatirea evenimentelor cu un potential risc in organizatii.

Mediul federated learning introduce un risc suplimentar: un adversar care controlează un număr mic de clienți poate influența disproportional modelul global dacă este integrat într-un moment critic al antrenării. În absența unor mecanisme robuste de apărare, actualizările malicioase sunt tratate ca fiind legitime, iar agregatorul nu are nicio modalitate directă de a le verifica.

Un alt efect important al acestui tip de atac este degradarea treptată a performanței modelului. În scenariile untargeted, scăderea acurateții globale poate trece neobservată în primele runde de antrenare, dar devine evidentă odată ce modelul converge către o reprezentare eronată a datelor. În scenariile targeted, atacul poate compromite decizii critice doar într-un subset de cazuri, ceea ce face detectarea mult mai dificilă și impactul mult mai nociv, mai ales în aplicații sensibile cum ar fi securitatea, domeniul medical sau sistemele autonome.

2.4 Alte Notiuni

În vederea elaborării soluției propuse în aceasta lucrare, se vor aminti celelalte concepte care stau la baza implementării propriu-zise. În acest capitol se vor detalia succint mecanismele ce stau la baza platformei propuse, modul de utilizare și scopul alegerii lor.

2.4.1 Docker

Docker reprezintă un set de servicii software de tip platformă ce utilizează virtualizarea la nivel de sistem de operare pentru a crea entități independente, numite containere. Aceste containere sunt create specific pentru a întreprinde anumite acțiuni și oferă un mediu izolat de execuție.

Un container este o instanță software ce vine impachetată cu programul aplicației și toate bibliotecile necesare dezvoltării ei. O imagine este vizualizată drept un sablon de instrucțiuni pentru crearea unui container cu un anumit tip de biblioteci necesare dezvoltării unei aplicații. De obicei, imaginile sunt construite pe baza unui fișier denumit Dockerfile care propune o serie de comenzi pentru crearea unui mediu personalizat.

Toate containerele Docker rulează prin intermediul Docker Engine, un serviciu ce rulează la nivelul sistemului de operare și oferă suport cross-platform (Linux, Windows, macOS).

Containerizarea diferă de virtualizarea tradițională prin faptul că containerele partajează același kernel al sistemului de operare gazdă, în timp ce mașinile virtuale (VM) necesită fiecare un sistem de operare complet. Această abordare face containerele Docker mult mai ușoare (de ordinul MB vs GB) și mai rapide la pornire (secunde vs minute) comparativ cu VM-urile.

Arhitectura platformei Docker este asemănătoare modelului client-server, fiind compusă din următoarele componente:

- **Dockerd** un proces daemon, identificabil drept server, ce gestionează tot fluxul de servicii, de la imagini și containere până la volume și rețele.
- **Application Binary Interfaces (API)** o suite de interfețe de comunicare și control al serverului
- **Comanda docker** o interfață în linie de comandă, docker

În contextul platformei dezvoltate, Docker oferă un mediu de dezvoltare automat în care se regăsește gazduita platformă publică de simulare. Toate informațiile despre fiecare simulare sunt stocate la nivelul unei baze de date PostgreSQL, în timp ce aplicația web este publică printr-un container frontend, iar în spate regăsim un container backend pentru transmiterea de comenzi serverului.

Comunicația dintre container are loc în același rețea locală Docker, iar informațiile despre fiecare simulare a clientului persistă în același volum partajat.

Pe lângă Dockerfile, serviciul Docker Engine oferă și posibilitatea creării unei configurații prestatibile pentru definirea de topologie de rețea de containere prin Docker Compose. Pe baza fișierelor Dockerfile în care sunt definite săboanele imaginilor și a unui fișier de configurație YAML a topologiei relațiilor dintre containere, serviciul Docker Compose permite implementarea unei infrastructuri întregi prin rularea și stergerea sa dintr-o serie de comenzi.

2.4.2 Python

2.4.3 Rest API

Capitolul 3:

Proiectare, Implementare si Testare

3.1 Cerintele Software

3.1.1 Cerintele functionale

3.1.2 Cerintele nefunctionale

3.2 Arhitectura platformei

3.2.1 Containere

3.2.2 Server

3.3 Testare

Capitolul 4:

Rezultate si Metrici Simulari

4.1 Evaluare Performante

4.1.1 Scalabilitatea Simularilor

4.1.2 Scalabilitatea platformei

4.2 Evaluare Rezultate

4.2.1 Performante Gaussian Noise

4.2.2 Performante Label-Flip

4.2.3 Performante Backdoor

Capitolul 5:

Concluzii si dezvoltare ulterioara

5.1 Starea Curentă

5.2 Dezvoltare Ulterioara

5.3 Tabele

Tabelele sunt aranjări a informației într-o structură formată din linii și coloane, care permite o mai bună observare a acesteia.

Mai jos apar două exemple. Primul tabel este de dimensiune mică. Al doilea, din cauza dimensiunii mai mari, are o orientare inversată și este plasat singur pe o pagină.

| Nume Complet | Funcție Ocupată |
|----------------|--------------------|
| Joshua Roob | Manager de Proiect |
| Asa Hauck | Artist Grafic |
| Harley Hagenes | Programator |

Tabel 5.1: Colaboratori la Realizarea Studiului

| Stat | Oraș | | Latitudine | Longitudine |
|----------------|------------------|------------|------------|-------------|
| South Carolina | Corwinberg | 86.609523 | 42.408007 | |
| Rhode Island | East Isaacmouth | 63.17309 | -13.786023 | |
| Mississippi | North Noblesstad | -31.316834 | 5.280483 | |
| Illinois | Grahamland | -39.853659 | -77.713676 | |
| Rhode Island | West Richardfort | 67.583131 | 31.858455 | |
| Florida | Port Roberta | 25.276026 | 83.71534 | |

Tabel 5.2: Locații de Conducere a Studiului

5.4 Imagini

Imaginile sunt utilizate în cadrul lucrării pentru exemplificarea unor idei în manieră vizuală.




Figura 5.1: Arhitectura unui calculator¹

5.5 Liste

Listele sunt simple serii de informații.

- Un item
- Unul dintre itemi
- Încă un item

Acestea pot conțin itemi identificați prin numere dacă indexarea sau sortarea sunt necesare.

1. Primul item
2. Al doilea item
3. Al treilea item

5.6 Formule Matematice

LATEX oferă un mod programatic de a construi formule matematice, după cum este cea de mai jos.

¹Arhitectura ilustrată este de fapt cea von Neumann.

$$\sum \mathbf{F} = 0 \Leftrightarrow \frac{d\mathbf{v}}{dt} = 0$$

5.7 Note de Subsol. Citări

Notele de subsol pot fi utile în cazul explicațiilor suplimentare (cum a fost cea referitoare la imaginea inclusă, la care sintaxa este puțin diferită din cauza plasării notei în cadrul legendei) sau a citărilor² care nu se pretează a fi trecute în bibliografie din cauza utilizării lor punctuale.

Pe de altă parte, sursele bibliografice citate intens [1] sunt marcate corespunzător și notate în bibliografie.

5.8 Etichete. Referințe

În cadrul surselor L^AT_EX a acestui document, apar *tag-uri* \label care creează o etichetă utilă referințelor interne. Acestea din urmă indică elemente din cadrul documentului curent (de exemplu, către tabelul 5.1).

Mai pot apărea referințe externe, către resurse din Internet (de exemplu, către *website-ul Wikipedia*).

²Cristian Lupascu, Cezar Plesca și Mihai Togan, "Privacy Preserving Morphological Operations for Digital Images", în (iun. 2020), pp. 183–188, doi: 10.1109/COMM48946.2020.9141997

Bibliografie

Cărți

- [1] Mihai Togan, *Cryptographic Technologies for Data Protection in Cloud*, Editura Matrix Rom, 2017.

Articole Științifice

- [2] Ionuț Dumitru și Mihai Togan, “Client Module with Multifactor Authentication for Remote Electronic Signature Generation Using Cryptography API: Next Generation”, în *Journal of Military Technology* 3 (iun. 2020), pp. 5–10, DOI: 10.32754/JMT.2020.1.01.